



GLM-4.7-Flash Q4_K_M · RTX 4080 SUPER · cache LRU 8 GiB

Avant Normalisation optimisée

Décodage · tokens/s



Prefill · secondes



Trois répétitions après chauffe ; points = mesures individuelles.
Débit de décodage rapporté par le serveur. Pas de comparaison avec les autres moteurs.