



Rbitnet — évolution des premières campagnes comparables

3 octobre 2026 • Ryzen 7 9800X3D / RTX 4080 SUPER • médiane de décodage, 32 tokens maximum

CPU Llama 3.2 1B Qwen3.5 2B GPT-OSS 20B GLM 4.7 Flash (MoE)



CUDA / placement hybride selon le modèle



Chargement initial de Qwen, GPT-OSS et GLM : échec. Aucune vitesse n'est attribuée à ces trois modèles avant leur prise en charge.

Même export par modèle, 16 threads, un client, chauffe exclue, trois mesures. Traits verticaux : min/max observés, pas un intervalle de confiance.

Contrôles courts : Llama/GPT-OSS/GLM 3/3 ; Qwen 2/3 après correction. Ils ne constituent pas une évaluation générale de qualité.


Les ablations à 128 tokens du 4 octobre et le comparatif final en cours sont présentés séparément ; aucune courbe ne mélange leurs protocoles.

Optimisations récentes — effets isolés, gains et régressions

Chaque panneau compare sa propre référence. Les gains ne s’additionnent pas et ne forment pas une chaîne de versions.


1. Llama — attention par tuiles KV (#103)

128 tokens • même campagne • +338.7%




2. Qwen — attention par tuiles KV (#103)

128 tokens • même campagne • +131.2%




3. GPT-OSS — pipeline résident (#106)

128 tokens • médianes des prompts longs de cette ablation




4. GPT-OSS — normalisation ordonnée (#124)

128 tokens • même CLI, DLL différente • +28.0%




5. CPU — sortie directe des lignes (prototype)

128 tokens • contexte 512 • prompt histoire • option désactivée par défaut




6. Qwen — décodage spéculatif (#123)

128 tokens • sorties identiques testées • ralentissement, option expérimentale




7. Llama — batching continu (#120)

8 clients • 798 tokens par vague • mesure fraîche • pas le débit par requête



8. MoE — arène d’experts (#121)

Budget experts 8192 MiB • gain de capacité • ce n’est pas la VRAM du processus



Ablations mono-client : chauffe exclue, deux mesures par prompt sauf mention contraire. Mesures descriptives ; aucune parité générale revendiquée.